

## 非线性最小二乘问题

### 第一章：

局部最优的必要条件是一阶导为 0，驻点可以按照如下方式去区分为极大极小值点：

1. 若  $F''(x_s)$  正定，则  $x_s$  点为极小值点
2. 若  $F''(x_s)$  负定，则  $x_s$  点为极大值点

其中， $F''(x_s)$  为对应点的海塞矩阵。对于非线性的目标函数，没办法求其导数为 0 的解析解，所以一般上通过迭代下降的方法，使得  $F(x)$  的值不断下降，也即下降条件： $F(x_{k+1}) < F(x_k)$

最小二乘问题的定义：

#### Definition 1.1. Least Squares Problem

Find  $x^*$ , a local minimizer for<sup>1)</sup>

$$F(x) = \frac{1}{2} \sum_{i=1}^m (f_i(x))^2,$$

where  $f_i : \mathbb{R}^n \mapsto \mathbb{R}$ ,  $i = 1, \dots, m$  are given functions, and  $m \geq n$ .

全局最小和局部最小的定义：

#### Definition 1.2. Global Minimizer

Given  $F : \mathbb{R}^n \mapsto \mathbb{R}$ . Find

$$x^+ = \operatorname{argmin}_x \{F(x)\}.$$

#### Definition 1.3. Local Minimizer

Given  $F : \mathbb{R}^n \mapsto \mathbb{R}$ . Find  $x^*$  so that

$$F(x^*) \leq F(x) \quad \text{for } \|x - x^*\| < \delta.$$

关于局部最优的一个局部最优导数为 0 定理和驻点的定义：

#### Theorem 1.5. Necessary condition for a local minimizer.

If  $x^*$  is a local minimizer, then

$$g^* \equiv F'(x^*) = 0.$$

#### Definition 1.6. Stationary point. If

$$g_s \equiv F'(x_s) = 0,$$

then  $x_s$  is said to be a *stationary point* for  $F$ .

### 第二章：

下降方法的定义：

**Algorithm 2.4. Descent method**

```

begin
   $k := 0$ ;  $\mathbf{x} := \mathbf{x}_0$ ;  $found := \mathbf{false}$            {Starting point}
  while (not  $found$ ) and ( $k < k_{\max}$ )
     $\mathbf{h}_d := \text{search\_direction}(\mathbf{x})$            {From  $\mathbf{x}$  and downhill}
    if (no such  $\mathbf{h}$  exists)
       $found := \mathbf{true}$                        { $\mathbf{x}$  is stationary}
    else
       $\alpha := \text{step\_length}(\mathbf{x}, \mathbf{h}_d)$        {from  $\mathbf{x}$  in direction  $\mathbf{h}_d$ }
       $\mathbf{x} := \mathbf{x} + \alpha \mathbf{h}_d$ ;  $k := k+1$        {next iterate}
  end

```

泰勒公式:

$$\begin{aligned}
 F(\mathbf{x} + \alpha \mathbf{h}) &= F(\mathbf{x}) + \alpha \mathbf{h}^\top \mathbf{F}'(\mathbf{x}) + O(\alpha^2) \\
 &\simeq F(\mathbf{x}) + \alpha \mathbf{h}^\top \mathbf{F}'(\mathbf{x}) \quad \text{for } \alpha \text{ sufficiently small.}
 \end{aligned}$$

下降方向  $\mathbf{h}$  满足  $\mathbf{h}^\top \mathbf{F}'(\mathbf{x}) < 0$

**Definition 2.6. Descent direction.**

$\mathbf{h}$  is a descent direction for  $F$  at  $\mathbf{x}$  if  $\mathbf{h}^\top \mathbf{F}'(\mathbf{x}) < 0$ .

选取步长:

$$\alpha_e = \operatorname{argmin}_{\alpha > 0} \{F(\mathbf{x} + \alpha \mathbf{h})\}.$$

最速下降法

- 令  $\mathbf{x}^{(0)}$  作为初始搜索点，并沿着梯度负方向构造一个新点  $\mathbf{x}^{(0)} - \alpha \nabla f(\mathbf{x}^{(0)})$ ，由泰勒定理可得

$$f(\mathbf{x}^{(0)} - \alpha \nabla f(\mathbf{x}^{(0)})) = f(\mathbf{x}^{(0)}) - \alpha \|\nabla f(\mathbf{x}^{(0)})\|^2 + o(\alpha)$$

- 因此，如果  $\nabla f(\mathbf{x}^{(0)}) \neq \mathbf{0}$ ，那么当  $\alpha > 0$  足够小时，有

$$f(\mathbf{x}^{(0)} - \alpha \nabla f(\mathbf{x}^{(0)})) < f(\mathbf{x}^{(0)})$$

- 可以设计一种方法实现以上理念。给定一个搜索点  $\mathbf{x}^{(k)}$  由此点出发，根据向量  $-\alpha_k \nabla f(\mathbf{x}^{(k)})$  指定的方向和幅值运动，构造新点  $\mathbf{x}^{(k+1)}$ ，其中， $\alpha_k$  是一个正实数，称为步长。这样，可得到迭代公式：

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha_k \nabla f(\mathbf{x}^{(k)})$$

## ■ 最速下降法

- 最速下降法是梯度方法的一种具体实现，其理念为在每次迭代中选择合适的步长  $\alpha_k$ ，使得目标函数值能够最大程度减小
- $\alpha_k$  满足：

$$\alpha_k = \arg \min_{\alpha \geq 0} f(\mathbf{x}^{(k)} - \alpha \nabla f(\mathbf{x}^{(k)}))$$

每一次迭代的相对增益

$$\lim_{\alpha \rightarrow 0} \frac{F(\mathbf{x}) - F(\mathbf{x} + \alpha \mathbf{h})}{\alpha \|\mathbf{h}\|} = -\frac{1}{\|\mathbf{h}\|} \mathbf{h}^\top \mathbf{F}'(\mathbf{x}) = -\|\mathbf{F}'(\mathbf{x})\| \cos \theta$$

选择梯度的负方向：

$$h_{sd} = -\nabla f(\mathbf{x})$$

- 如果有  $\nabla f(\mathbf{x}^{(k)}) = \mathbf{0}$ ，说明  $\mathbf{x}^{(k)}$  满足局部极小点一阶必要条件，这可以作为设计迭代停止规则的基础。
- 在实际应用中，采用数值计算方法很难恰好得到梯度为零的结果，因此， $\nabla f(\mathbf{x}^{(k)}) = \mathbf{0}$  并不适合直接作为停止规则。
- 一种实用的停止规则是计算梯度的范数  $\|\nabla f(\mathbf{x}^{(k)})\|$ ，如果小于某个预设的阈值，则迭代停止。

## 牛顿法

### ■ 牛顿法

- 求解一元单值函数  $f$  在区间上求极小点的问题
- 假设函数连续二阶可微，即  $x^{(k)}$  处的  $f'(x^{(k)})$  和  $f''(x^{(k)})$  均可求得。
- 构造一个经过点  $(x^{(k)}, f(x^{(k)}))$  处的二次函数，该函数在的一阶和二阶导数分别为  $f'(x^{(k)})$  和  $f''(x^{(k)})$ ，如下所示：

$$q(x) = f(x^{(k)}) + f'(x^{(k)})(x - x^{(k)}) + \frac{1}{2}f''(x^{(k)})(x - x^{(k)})^2$$

- $q(x^{(k)})$  为  $f(x^{(k)})$  在  $x^{(k)}$  的二阶近似。

### ■ 牛顿法

- 求函数  $f$  的极小点可近似于求解  $q$  的极小点
- 函数  $q$  的极小点应满足一阶必要条件：

$$0 = q'(x) = f'(x^{(k)}) + f''(x^{(k)})(x - x^{(k)})$$

- 令  $x = x^{(k+1)}$ ，可得：

$$x^{(k+1)} = x^{(k)} - \frac{f'(x^{(k)})}{f''(x^{(k)})}$$

从驻点出发，由于驻点的一阶导数为 0，结合泰勒展开：

$$\begin{aligned}\mathbf{F}'(\mathbf{x}+\mathbf{h}) &= \mathbf{F}'(\mathbf{x}) + \mathbf{F}''(\mathbf{x})\mathbf{h} + O(\|\mathbf{h}\|^2) \\ &\simeq \mathbf{F}'(\mathbf{x}) + \mathbf{F}''(\mathbf{x})\mathbf{h} \quad \text{for } \|\mathbf{h}\| \text{ sufficiently small}\end{aligned}$$

使一阶导为 0：

$$\mathbf{H}\mathbf{h}_n = -\mathbf{F}'(\mathbf{x}) \quad \text{with } \mathbf{H} = \mathbf{F}''(\mathbf{x})$$

下一次的迭代表示为：  $\mathbf{x} := \mathbf{x} + \mathbf{h}_n$ 。但是这个思路目的是为了求可能的驻点，在下降的方向上，会不会出现问题呢，因此这里还需要验证一下：

假设这个海塞矩阵  $\mathbf{H}$  是正定的，也就是说这个驻点是极小值点。我们对如下式子两边同乘一个  $\mathbf{h}_n^T$ 。

$\mathbf{H}\mathbf{h}_n = -\mathbf{F}'(\mathbf{x})$  就变成了  $0 < \mathbf{h}_n^T \mathbf{H} \mathbf{h}_n = -\mathbf{h}_n^T \mathbf{F}'(\mathbf{x})$ ， $\mathbf{h}_n^T \mathbf{H} \mathbf{h}_n$  是一个二次型，一定正定，满足定义 2.6，使得我们所求的方向一定是一个下降方向。

**Definition 2.6. Descent direction.**

$\mathbf{h}$  is a descent direction for  $F$  at  $\mathbf{x}$  if  $\mathbf{h}^T \mathbf{F}'(\mathbf{x}) < 0$ .

基于最速下降和牛顿法的混合模式：

```

if  $\mathbf{F}''(\mathbf{x})$  is positive definite
     $\mathbf{h} := \mathbf{h}_n$ 
else
     $\mathbf{h} := \mathbf{h}_{sd}$ 
 $\mathbf{x} := \mathbf{x} + \alpha \mathbf{h}$ 

```

这里的  $\mathbf{h}_{sd}$  是由最速下降法得到的下降方向，而  $\alpha$  是由线性搜索得到的。至于如何去检查这个  $\mathbf{h}$  是否正定，作者这里也提了一嘴 Cholesky 方法。

线性搜索的核心选取步长  $\alpha$ ：

$$\alpha_e = \operatorname{argmin}_{\alpha > 0} \{F(\mathbf{x} + \alpha \mathbf{h})\}$$

满足如下条件时会停下来：



$|\varphi'(\alpha_s)| \leq \tau |\varphi'(0)|$  而  $t$  在这里是一个比较小的正值。但是准确的线性搜索可能是非常浪费时间的，而我们实际上不是真的很需要一个非常精准的  $\varphi$ ，因此更多的我们会使用软线性搜索：

$$\varphi(\alpha_s) \leq \varphi(0) + \gamma_1 \cdot \varphi'(0) \cdot \alpha \quad \text{with } 0 < \gamma_1 < 1$$

但是仅有这一条还不够，这样可能导致这个新的  $a$  值太过接近初始值，因此还需要加上以下这条限制：

$$\varphi'(\alpha_s) \geq \gamma_2 \cdot \varphi'(0) \quad \text{with } \gamma_1 < \gamma_2 < 1$$

在满足以上两条 条件时，这个  $a$  就被我们接受为需要的步长。

### 信任区域法和阻尼法：

我们首先对当前估计状态附近的原代价函数进行一个近似：

$$F(\mathbf{x}+\mathbf{h}) \simeq L(\mathbf{h}) \equiv F(\mathbf{x}) + \mathbf{h}^\top \mathbf{c} + \frac{1}{2} \mathbf{h}^\top \mathbf{B} \mathbf{h} .$$
 这里的  $\mathbf{c}$  和  $\mathbf{B}$  都是对称阵。

在信任区域法中，我们首先假设一致一个正数  $\delta$  且在这个半径内我们的模型足够精确。那么步长可以按照以下方式来确定：

$$\mathbf{h} = \mathbf{h}_{tr} \equiv \operatorname{argmin}_{\|\mathbf{h}\| \leq \Delta} \{L(\mathbf{h})\}.$$

而在阻尼法中，步长按以下方法来确定：

$$\mathbf{h} = \mathbf{h}_{dm} \equiv \operatorname{argmin}_{\mathbf{h}} \{L(\mathbf{h}) + \frac{1}{2} \mu \mathbf{h}^\top \mathbf{h}\}$$
 后面加的这一项相当于对大步长的惩罚。

介绍这两个东西有什么用呢？这两种方法在实现上更加简单一点。那么相对于最速下降法和牛顿法，如何验证这两种估计方法的精度呢？给出如下方法：

定义：  $\rho = \frac{F(\mathbf{x}) - F(\mathbf{x}+\mathbf{h})}{L(\mathbf{0}) - L(\mathbf{h})}$  ，用来表示实际与预测下降之间的比率。如果这个比率太小，说明说明实际下降误差过小于模型下降误差，模型计算的下降

步长过大，因此对于信任区域法来说，要减小  $\delta$  的值，对于阻尼法来说，则要增大阻尼参数  $\mu$ 。反之亦然。

### 第三章

非线性最小二乘问题：

对于给定的向量函数  $\mathbf{R}^n \mapsto \mathbf{R}^m$ ，且  $m \geq n$  我们想最小化这个向量函数的二范数  $\|\mathbf{f}(\mathbf{x})\|$ ，也即相当于去找  $\mathbf{x}^* = \operatorname{argmin}_{\mathbf{x}} \{F(\mathbf{x})\}$ ，这里的：

$$F(\mathbf{x}) = \frac{1}{2} \sum_{i=1}^m (f_i(\mathbf{x}))^2 = \frac{1}{2} \|\mathbf{f}(\mathbf{x})\|^2 = \frac{1}{2} \mathbf{f}(\mathbf{x})^\top \mathbf{f}(\mathbf{x})$$

假定  $\mathbf{f}$  的泰勒展开如下：

$$\mathbf{f}(\mathbf{x}+\mathbf{h}) = \mathbf{f}(\mathbf{x}) + \mathbf{J}(\mathbf{x})\mathbf{h} + O(\|\mathbf{h}\|^2)$$

$$(\mathbf{J}(\mathbf{x}))_{ij} = \frac{\partial f_i}{\partial x_j}(\mathbf{x})$$

这里的  $\mathbf{J}$  是雅克比矩阵。

由于  $\frac{\partial F}{\partial x_j}(\mathbf{x}) = \sum_{i=1}^m f_i(\mathbf{x}) \frac{\partial f_i}{\partial x_j}(\mathbf{x})$ ，因此大  $F$  的导数可以表示为：

$$\mathbf{F}'(\mathbf{x}) = \mathbf{J}(\mathbf{x})^\top \mathbf{f}(\mathbf{x})$$

对于大  $F$  的二阶导，我们需要首先引入海塞矩阵：

$$\frac{\partial^2 F}{\partial x_j \partial x_k}(\mathbf{x}) = \sum_{i=1}^m \left( \frac{\partial f_i}{\partial x_j}(\mathbf{x}) \frac{\partial f_i}{\partial x_k}(\mathbf{x}) + f_i(\mathbf{x}) \frac{\partial^2 f_i}{\partial x_j \partial x_k}(\mathbf{x}) \right)$$

因此 
$$\mathbf{F}''(\mathbf{x}) = \mathbf{J}(\mathbf{x})^\top \mathbf{J}(\mathbf{x}) + \sum_{i=1}^m f_i(\mathbf{x}) \mathbf{f}_i''(\mathbf{x})$$

## 第一节:高斯牛顿法

高斯-牛顿迭代法的基本思想是, 使用泰勒级数展开式去近似地代替非线性回归模型, 然后通过多次迭代, 多次修正回归系数, 使回归系数不断通过逼近非线性回归模型的最佳回归系数, 最后使原模型的残差平方和达到最小。

首先在估计点附近展开小  $\mathbf{f}$ :  $\mathbf{f}(\mathbf{x}+\mathbf{h}) \simeq \boldsymbol{\ell}(\mathbf{h}) \equiv \mathbf{f}(\mathbf{x}) + \mathbf{J}(\mathbf{x})\mathbf{h}$ , 带入进大  $F$ , 有:

$$\begin{aligned} F(\mathbf{x}+\mathbf{h}) &\simeq L(\mathbf{h}) \equiv \frac{1}{2}\boldsymbol{\ell}(\mathbf{h})^\top \boldsymbol{\ell}(\mathbf{h}) \\ &= \frac{1}{2}\mathbf{f}^\top \mathbf{f} + \mathbf{h}^\top \mathbf{J}^\top \mathbf{f} + \frac{1}{2}\mathbf{h}^\top \mathbf{J}^\top \mathbf{J} \mathbf{h} \\ &= F(\mathbf{x}) + \mathbf{h}^\top \mathbf{J}^\top \mathbf{f} + \frac{1}{2}\mathbf{h}^\top \mathbf{J}^\top \mathbf{J} \mathbf{h} \end{aligned}$$

高斯牛顿法的步长

$\mathbf{h}_{\text{gn}}$  会试图最小化  $L(\mathbf{h})$ :  $\mathbf{h}_{\text{gn}} = \operatorname{argmin}_{\mathbf{h}} \{L(\mathbf{h})\}$

$$\mathbf{L}'(\mathbf{h}) = \mathbf{J}^\top \mathbf{f} + \mathbf{J}^\top \mathbf{J} \mathbf{h}, \quad \mathbf{L}''(\mathbf{h}) = \mathbf{J}^\top \mathbf{J},$$

类似于牛顿法, 还是找一阶导数为 0 的点, 因此有

$$(\mathbf{J}^\top \mathbf{J})\mathbf{h}_{\text{gn}} = -\mathbf{J}^\top \mathbf{f}$$

$$\text{Solve } (\mathbf{J}^\top \mathbf{J})\mathbf{h}_{\text{gn}} = -\mathbf{J}^\top \mathbf{f}$$

综上:  $\mathbf{x} := \mathbf{x} + \alpha \mathbf{h}_{\text{gn}}$

这里的步长仍然需要用线性搜索去实现。

传统的高斯牛顿法中  $\alpha$  是一个定值为 1。

## 第二节: The Levenberg–Marquardt Method



**Algorithm 3.16. Levenberg–Marquardt method****begin** $k := 0; \quad \nu := 2; \quad \mathbf{x} := \mathbf{x}_0$  $\mathbf{A} := \mathbf{J}(\mathbf{x})^\top \mathbf{J}(\mathbf{x}); \quad \mathbf{g} := \mathbf{J}(\mathbf{x})^\top \mathbf{f}(\mathbf{x})$  $found := (\|\mathbf{g}\|_\infty \leq \varepsilon_1); \quad \mu := \tau * \max\{a_{ii}\}$ **while** (not found) and ( $k < k_{\max}$ ) $k := k+1; \quad \text{Solve } (\mathbf{A} + \mu \mathbf{I})\mathbf{h}_{lm} = -\mathbf{g}$ **if**  $\|\mathbf{h}_{lm}\| \leq \varepsilon_2(\|\mathbf{x}\| + \varepsilon_2)$  $found := \mathbf{true}$ **else** $\mathbf{x}_{\text{new}} := \mathbf{x} + \mathbf{h}_{lm}$  $\varrho := (F(\mathbf{x}) - F(\mathbf{x}_{\text{new}}))/(L(\mathbf{0}) - L(\mathbf{h}_{lm}))$ **if**  $\varrho > 0$  {step acceptable} $\mathbf{x} := \mathbf{x}_{\text{new}}$  $\mathbf{A} := \mathbf{J}(\mathbf{x})^\top \mathbf{J}(\mathbf{x}); \quad \mathbf{g} := \mathbf{J}(\mathbf{x})^\top \mathbf{f}(\mathbf{x})$  $found := (\|\mathbf{g}\|_\infty \leq \varepsilon_1)$  $\mu := \mu * \max\{\frac{1}{3}, 1 - (2\varrho - 1)^3\}; \quad \nu := 2$ **else** $\mu := \mu * \nu; \quad \nu := 2 * \nu$ **end**

LM 算法是一种阻塞式高斯牛顿法。这也是使用最广泛的非线性最小二乘算法。其区别在于其步长  $\mathbf{h}_{lm}$  的计算按照如下方法实现：

$$(\mathbf{J}^\top \mathbf{J} + \mu \mathbf{I})\mathbf{h}_{lm} = -\mathbf{g} \quad \text{with } \mathbf{g} = \mathbf{J}^\top \mathbf{f} \text{ and } \mu \geq 0$$

这里的  $\mu$  是阻塞系数，类似于阻塞牛顿法，其也有如下几种可能的影响：

如果  $\mu$  全为正数，那么这就能保证  $\mathbf{h}_{lm}$  是下降方向的

如果  $\mu$  特别大，我们可以忽略掉其他的東西，解出  $\mathbf{h}$  有：

$$\mathbf{h}_{lm} \simeq -\frac{1}{\mu} \mathbf{g} = -\frac{1}{\mu} \mathbf{F}'(\mathbf{x})$$

反之，如果  $\mu$  特别小，那么这个算法其实就和高斯牛顿法差不多了。可以看出这个  $\mu$  对于下降方向以及步长的大小都有着比较重要的影响。

增益率：
$$\varrho = \frac{F(\mathbf{x}) - F(\mathbf{x} + \mathbf{h}_{lm})}{L(\mathbf{0}) - L(\mathbf{h}_{lm})}$$
，分母和是线性模型预测的结果的增益

$$\begin{aligned}
L(\mathbf{0}) - L(\mathbf{h}_{lm}) &= -\mathbf{h}_{lm}^\top \mathbf{J}^\top \mathbf{f} - \frac{1}{2} \mathbf{h}_{lm}^\top \mathbf{J}^\top \mathbf{J} \mathbf{h}_{lm} \\
&= -\frac{1}{2} \mathbf{h}_{lm}^\top (2\mathbf{g} + (\mathbf{J}^\top \mathbf{J} + \mu \mathbf{I} - \mu \mathbf{I}) \mathbf{h}_{lm}) \\
&= \frac{1}{2} \mathbf{h}_{lm}^\top (\mu \mathbf{h}_{lm} - \mathbf{g}) .
\end{aligned}$$

停止准则，我们希望能够反应一个最小值点而并非一个局部的极小值点，也即  $\mathbf{F}'(\mathbf{x}^*) = \mathbf{g}(\mathbf{x}^*) = \mathbf{0}$ ，因此我们可以用  $\|\mathbf{g}\|_\infty \leq \varepsilon_1$ ，这里  $\varepsilon$  是一个非常小的值。或者使用： $\|\mathbf{x}_{new} - \mathbf{x}\| \leq \varepsilon_2(\|\mathbf{x}\| + \varepsilon_2)$ 。

### 第三节：Dog Leg Method

#### Algorithm 3.21. Dog Leg Method

```

begin
   $k := 0; \mathbf{x} := \mathbf{x}_0; \Delta := \Delta_0; \mathbf{g} := \mathbf{J}(\mathbf{x})^\top \mathbf{f}(\mathbf{x})$  {1°}
   $found := (\|\mathbf{f}(\mathbf{x})\|_\infty \leq \varepsilon_3) \text{ or } (\|\mathbf{g}\|_\infty \leq \varepsilon_1)$  {2°}
  while (not found) and ( $k < k_{max}$ )
     $k := k+1$ ; Compute  $\alpha$  by (3.19)
     $\mathbf{h}_{sd} := -\alpha \mathbf{g}$ ; Solve  $\mathbf{J}(\mathbf{x}) \mathbf{h}_{gn} \simeq -\mathbf{f}(\mathbf{x})$  {3°}
    Compute  $\mathbf{h}_{dl}$  by (3.20)
    if  $\|\mathbf{h}_{dl}\| \leq \varepsilon_2(\|\mathbf{x}\| + \varepsilon_2)$ 
      found := true
    else
       $\mathbf{x}_{new} := \mathbf{x} + \mathbf{h}_{dl}$ 
       $\varrho := (F(\mathbf{x}) - F(\mathbf{x}_{new})) / (L(\mathbf{0}) - L(\mathbf{h}_{dl}))$  {4°}
      if  $\varrho > 0$ 
         $\mathbf{x} := \mathbf{x}_{new}; \mathbf{g} := \mathbf{J}(\mathbf{x})^\top \mathbf{f}(\mathbf{x})$ 
         $found := (\|\mathbf{f}(\mathbf{x})\|_\infty \leq \varepsilon_3) \text{ or } (\|\mathbf{g}\|_\infty \leq \varepsilon_1)$ 
        if  $\varrho > 0.75$  {5°}
           $\Delta := \max\{\Delta, 3\|\mathbf{h}_{dl}\|\}$ 
        elseif  $\varrho < 0.25$ 
           $\Delta := \Delta/2; found := (\Delta \leq \varepsilon_2(\|\mathbf{x}\| + \varepsilon_2))$  {6°}
      end
  end
end

```

LM 算法需要对每一个待估参数求偏导，所以如果你的拟合函数  $f$  非常复杂，或者待估参数相当多地，那么可能不适合使用 LM 算法，而可以选择 **Dog Leg Method** 算法。

最速下降法的方向向量可以按以下方法给出： $\mathbf{h}_{sd} = -\mathbf{g} = -\mathbf{J}(\mathbf{x})^\top \mathbf{f}(\mathbf{x})$

$$\begin{aligned}
\mathbf{f}(\mathbf{x} + \alpha \mathbf{h}_{sd}) &\simeq \mathbf{f}(\mathbf{x}) + \alpha \mathbf{J}(\mathbf{x}) \mathbf{h}_{sd} \\
\Downarrow \\
F(\mathbf{x} + \alpha \mathbf{h}_{sd}) &\simeq \frac{1}{2} \|\mathbf{f}(\mathbf{x}) + \alpha \mathbf{J}(\mathbf{x}) \mathbf{h}_{sd}\|^2 \\
&= F(\mathbf{x}) + \alpha \mathbf{h}_{sd}^\top \mathbf{J}(\mathbf{x})^\top \mathbf{f}(\mathbf{x}) + \frac{1}{2} \alpha^2 \|\mathbf{J}(\mathbf{x}) \mathbf{h}_{sd}\|^2
\end{aligned}$$

$$\alpha = - \frac{\mathbf{h}_{sd}^\top \mathbf{J}(\mathbf{x})^\top \mathbf{f}(\mathbf{x})}{\|\mathbf{J}(\mathbf{x}) \mathbf{h}_{sd}\|^2} = \frac{\|\mathbf{g}\|^2}{\|\mathbf{J}(\mathbf{x}) \mathbf{g}\|^2}$$


$\alpha$  的最小值可以由以下算式得到：

使用如下方法来选择最终步长，其中置信区域半径为  $\delta$

```

if  $\|\mathbf{h}_{gn}\| \leq \Delta$ 
     $\mathbf{h}_{dl} := \mathbf{h}_{gn}$ 
elseif  $\|\alpha \mathbf{h}_{sd}\| \geq \Delta$ 
     $\mathbf{h}_{dl} := (\Delta / \|\mathbf{h}_{sd}\|) \mathbf{h}_{sd}$ 
else
     $\mathbf{h}_{dl} := \alpha \mathbf{h}_{sd} + \beta (\mathbf{h}_{gn} - \alpha \mathbf{h}_{sd})$ 
    with  $\beta$  chosen so that  $\|\mathbf{h}_{dl}\| = \Delta$ .

```



**Figure 3.4.** Trust region and Dog Leg step.<sup>4)</sup>